

UNIVERSIDAD DEL VALLE DE GUATEMALA
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN
CC3084 DATA SCIENCE · SEMESTRE II 2026

SignBridge ASL

Prototipo de reconocimiento del alfabeto de señas

Informe final del Laboratorio 3: análisis exploratorio, preprocesamiento, comparación de modelos, evaluación fuera del conjunto de datos y reflexión de accesibilidad.

INTEGRANTES

Anggie Quezada · Jonathan Díaz · Iris Ayala

REPOSITORIO

<https://github.com/Qu3zada22/Laboratorio3-ds>

Guatemala, agosto de 2026

Resumen ejecutivo

Se desarrolló y evaluó un prototipo de clasificación de imágenes estáticas para las 29 clases del conjunto ASL Alphabet: las letras A–Z y las categorías *del*, *nothing* y *space*. El objetivo académico fue recorrer un flujo reproducible de ciencia de datos y contrastar el desempeño interno con condiciones de captura más cercanas a un producto.

0.986590 Accuracy final de CNN 2 en test reservado	0.133333 Accuracy en 15 fotografías propias	0.853257 Brecha entre test y fotografías propias
--	---	--

La mejor alternativa fue la CNN 2 base, seleccionada exclusivamente por su accuracy de validación de 0.986973. En el test reservado obtuvo pérdida 0.059055 y accuracy 0.986590. Sin embargo, solo acertó 2 de 15 fotografías propias. Esta diferencia revela un cambio de dominio importante: el alto desempeño dentro del conjunto no demuestra por sí solo robustez ante otros fondos, cámaras, encuadres, iluminaciones o escalas de mano.

Lectura de producto. El prototipo demuestra viabilidad para un entorno controlado, pero no está listo para uso real. SignBridge necesitaría datos más diversos, separación por persona o sesión, evaluación por subgrupos, calibración de confianza y una experiencia que permita abstención y corrección.

Contenido y trazabilidad

- | | |
|---|---|
| 1. Contexto del producto y alcance | 6. Evaluación con fotografías propias |
| 2. Conjunto de datos y EDA | 7. Accesibilidad, sesgo y uso responsable |
| 3. Construcción de conjuntos y preprocesamiento | 8. Limitaciones |
| 4. Modelos y resultados medidos | 9. Conclusiones y recomendaciones |
| 5. Aumento de datos | |

Fuente de evidencia. Todas las cifras y figuras provienen de los resultados almacenados en el notebook ejecutado notebooks/01_eda_preprocessing.ipynb. No se reentrenaron modelos para elaborar este informe.

1. Contexto del producto y alcance

SignBridge se plantea como un apoyo para reducir barreras de comunicación mediante reconocimiento visual. En este laboratorio, su alcance se limita a clasificar una imagen estática y centrada en una de 29 categorías. No constituye traducción de ASL: una lengua de señas incorpora movimiento, expresiones faciales, gramática, espacio y contexto.

El trabajo cubre indexación de imágenes, análisis exploratorio, partición estratificada, preprocesamiento, dos arquitecturas CNN, tres redes densas, tres configuraciones de Random Forest, aumento de datos y una evaluación externa pequeña con fotografías propias. La selección de modelos usa validación; el test se reserva para una única evaluación final.

2. Conjunto de datos y análisis exploratorio

2.1 Composición y estrategia de muestra

El conjunto contiene **87,000 imágenes JPEG RGB de 200×200 píxeles**, distribuidas en 29 clases balanceadas con aproximadamente 3,000 imágenes por clase. Para inspeccionar variabilidad sin cargar todo el conjunto en memoria, se construyó primero un índice de rutas y etiquetas. Las visualizaciones usan muestras representativas y reproducibles, mientras el entrenamiento emplea 600 imágenes por clase.




Figura 1. Muestras representativas de ASL. Las clases A, B, C, L y Y muestran variación de ángulo, iluminación, fondo, encuadre y apariencia de la mano, aunque mantienen la configuración distintiva de cada señal.




Figura 2. Distribución por clase. La igualdad de frecuencias evita recurrir a sobremuestreo o pesos de clase; también hace que accuracy sea una medida interna interpretable, aunque no cubre equidad entre condiciones o personas.

2.2 Variabilidad y grupos visualmente similares

La dificultad no depende únicamente del balance. Varias señas se distinguen por detalles finos: posición del pulgar, separación o cruce de dedos y orientación de la muñeca. Se identificaron los grupos M–N–S, U–V–R, K–V–P, G–H y A–T–S como candidatos razonables a confusión visual.



Figura 3. Grupos visualmente confundibles. La comparación confirma que pequeñas diferencias locales separan clases. Esto favorece modelos convolucionales capaces de aprender patrones espaciales y exige capturas donde dedos y orientación sean legibles.

2.3 Brillo como variable de captura




Figura 4. Brillo promedio por clase. Las distribuciones se superponen ampliamente, por lo que el brillo no separa de forma general las señas. La clase *nothing* presenta un centro más alto y existen rangos internos amplios; la iluminación puede actuar como señal secundaria del conjunto.

3. Construcción de conjuntos y preprocesamiento

3.1 Partición y submuestra

El test provisto por Kaggle contiene solo una imagen por clase y no permite una estimación estable. Por ello se construyó una partición propia a partir del directorio de entrenamiento: **70% entrenamiento, 15% validación y 15% prueba**, manteniendo estratificación por clase. El test permaneció fuera de la selección de arquitectura e hiperparámetros.

Por costo computacional se tomó una submuestra de **600 imágenes por clase**, aproximadamente 17,400 imágenes, preservando las proporciones del split estratificado. Esta decisión reduce cerca de cinco veces el volumen frente al conjunto completo y permite comparar varias familias de modelos bajo el mismo protocolo.

3.2 Transformación de entrada

Etapa	Decisión	Justificación
Resolución	64 × 64, RGB	Reduce memoria y tiempo, conservando estructura espacial suficiente para el prototipo.
Escala	Normalización de píxeles a [0, 1]	Estabiliza la optimización de redes neuronales.
Etiquetas	Codificador ajustado únicamente con entrenamiento	Evita incorporar información de validación o test al preprocesamiento aprendido.
Procesamiento adicional	Sin filtros, segmentación ni ecualización	Mantiene un flujo simple y reproducible; fondo e iluminación quedan expuestos como parte del cambio de dominio.
Fotografías propias	Relleno cuadrado centrado y resize a 64 × 64	Conserva la relación de aspecto y evita deformar la geometría de la mano.




Figura 5. Efecto del preprocesamiento. La reducción conserva la configuración general, pero elimina detalle fino. En fotografías rectangulares, el relleno evita estiramiento; aun así, puede introducir bordes negros y reducir la escala efectiva de la mano.

4. Modelos y resultados medidos

4.1 Redes convolucionales

La CNN 1 funciona como línea base compacta. La CNN 2 incrementa profundidad y filtros, amplía la capacidad densa e incorpora dropout. Ambas se entrenaron sobre la misma partición; su comparación se realizó con accuracy y pérdida de validación, junto con las curvas de aprendizaje.

Modelo	Condición	Accuracy de validación	Lectura
CNN 1	Base	0.933333	Convergencia rápida y separación posterior entre pérdidas; evidencia de sobreajuste.
CNN 2	Base	0.986973	Pérdidas bajas y próximas; mejor arquitectura base.
CNN 1	Con aumento	0.970498	Mejora sustancial frente a su línea base.
CNN 2	Con aumento	0.980460	Resultado alto, pero inferior a CNN 2 base.




Figura 6. Curvas de aprendizaje de las CNN base. CNN 1 lleva la pérdida de entrenamiento casi a cero mientras validación oscila; CNN 2 mantiene trayectorias más cercanas y una pérdida de validación baja.




Figura 7. Matriz de confusión de CNN 2. La concentración sobre la diagonal y los errores aislados son coherentes con 0.986973 de accuracy. La gráfica no anota conteos por celda, por lo que no se atribuyen cantidades exactas a pares específicos.

4.2 Redes densas

Se compararon tres configuraciones fully-connected para variar capacidad y regularización. Las variantes de 128 unidades y 256 → 128 con dropout se estabilizaron cerca del nivel de azar para 29 clases; solo 256 → 128 aprendió una separación útil, aunque muy inferior a las CNN.

Configuración	Accuracy de validación	Resultado
Densa 128	0.034483	No aprendió una frontera útil.
Densa 256 → 128	0.662835	Mejor variante densa; pérdida de validación 1.001914.
Densa 256 → 128 + dropout 0.30	0.034483	No mejoró bajo esta configuración.

4.3 Random Forest y comparación global

Árboles	Accuracy de validación	Decisión
100	0.965134	Referencia inicial.
300	0.968966	Seleccionado.
500	0.968966	Empata con 300; no justifica mayor costo.

En caso de empate se eligió el bosque de 300 árboles por eficiencia. La comparación entre familias ordenó CNN 2, Random Forest, CNN 1 y la red densa 256→128. Este resultado muestra el valor de preservar relaciones espaciales mediante convoluciones.




Figura 8. Comparación de modelos en validación. CNN 2 base lidera con 0.986973. Random Forest constituye una línea base competitiva, pero no supera a la arquitectura convolucional.

4.4 Evaluación final reservada

CNN 2	0.059055	0.986590
Modelo final: variante base	Pérdida en test	Accuracy en test

La CNN 2 base se fijó antes de consultar el test. El resultado confirma desempeño interno alto, pero debe interpretarse junto con el riesgo de fotogramas casi duplicados y la evaluación externa descrita más adelante.

5. Aumento de datos

Se reentrenaron CNN 1 y CNN 2 con rotaciones pequeñas, zoom moderado, traslación y cambios de contraste. Estas transformaciones simulan variaciones plausibles de cámara, encuadre e iluminación sin alterar deliberadamente la configuración de la mano.

No se aplicaron reflejos horizontales ni verticales. En señas, la lateralidad, orientación de la palma, dirección y relación entre dedos son componentes semánticos; un reflejo puede generar una postura inválida o cambiar el significado. No es equivalente al caso de objetos cuya categoría permanece ante un espejo.




Figura 9. Efecto del aumento. CNN 1 sube de 0.933333 a 0.970498, consistente con una regularización útil. CNN 2 baja ligeramente de 0.986973 a 0.980460: las variaciones añadidas no aportaron una ventaja para una arquitectura base que ya generalizaba bien en validación.

El efecto distinto entre arquitecturas impide afirmar que el aumento siempre mejora. En CNN 1 reduce sobreajuste y amplía invariancias útiles; en CNN 2 puede introducir una tarea más difícil o variaciones que no coinciden exactamente con validación. Por ello se conserva CNN 2 base según el criterio medido, sin usar test para resolver la selección.

6. Evaluación con fotografías propias

6.1 Protocolo y resultados

La prueba externa utilizó **15 imágenes únicas** de exactamente tres participantes, identificados únicamente mediante seudónimos. Cada persona aportó cinco señas distintas. El notebook verificó participantes, cobertura y hashes antes de predecir. Los resultados no deben usarse para comparar a las personas: la unidad de análisis es el comportamiento del sistema ante un dominio nuevo.

Participante	Señas distintas	Aciertos	Accuracy
Orión	C, F, I, L, S	1 / 5	0.200000
Nébula	Q, R, U, V, X	1 / 5	0.200000
Láctea	A, B, D, F, L	0 / 5	0.000000
Total	15 imágenes únicas	2 / 15	0.133333




Figura 10. Evaluación con fotografías propias. El montaje permite contrastar predicción, confianza, fondo, encuadre y escala. Las bandas negras proceden del relleno cuadrado que conserva la relación de aspecto.

6.2 Patrones de error y cambio de dominio

La diferencia entre test y fotografías propias es **0.853257**, equivalente a 85.3257 puntos porcentuales. Las predicciones repetidas más frecuentes fueron *space* (4), *I* (2), *Y* (2) y *K* (2). Además, se observaron **nueve errores con confianza igual o mayor a 0.80**. La repetición de pocas clases y la alta seguridad en errores sugieren sobreconfianza y dependencia de rasgos del entorno de entrenamiento.

Las fotografías propias difieren en fondo, cámara, iluminación, distancia, encuadre, orientación y escala efectiva. El padding evita deformar la mano, pero introduce bordes y puede reducir su tamaño relativo. Estos factores explican un **cambio de dominio**; no indican una falla de las personas participantes. El tamaño de la muestra tampoco permite estimar rendimiento poblacional.

7. Accesibilidad, sesgo y uso responsable

Un sistema accesible no puede depender de una predicción automática única. Debe comunicar incertidumbre, permitir correcciones y ofrecer alternativas cuando la cámara o el modelo no sean confiables. También debe evitar presentar clasificación de letras aisladas como traducción completa de ASL.

Riesgo	Medición recomendada	Acción concreta
Tono de piel e iluminación	Accuracy, tasa de abstención y matriz de confusión por rangos documentados, con tamaño muestral.	Recolectar combinaciones equilibradas de tonos y luz; revisar brechas antes del despliegue.
Ángulo, cámara y encuadre	Métricas por dispositivo, distancia, orientación y condición de fondo.	Separar evaluación por sesión y dispositivo; incluir guías de encuadre no restrictivas.
Tamaño y proporciones de mano	Errores por subgrupo, sin usar rasgos como identificadores.	Ampliar participación y verificar que el preprocesamiento no reduzca desproporcionadamente ciertas manos.
Sobreconfianza	Calibración, precisión por nivel de confianza y errores de alta confianza.	Permitir abstención bajo umbral calibrado y mostrar una vía clara para corregir la salida.
Falta de legitimidad de uso	Pruebas de usabilidad y aceptación cualitativa.	Diseñar y evaluar con participación remunerada de personas de la comunidad sorda y usuarias de ASL.

La recolección debe contar con consentimiento informado, finalidad limitada, control de acceso y eliminación de fotografías cuando dejen de ser necesarias. Los reportes por subgrupo deben evitar reidentificación y siempre acompañar la métrica con el tamaño de muestra. Si persisten brechas, corresponde recolectar y ajustar antes de desplegar, no trasladar la carga a quienes usan el sistema.

8. Limitaciones

- **Fotogramas casi duplicados.** El conjunto parece contener secuencias de video; un split aleatorio puede ubicar cuadros muy similares en entrenamiento, validación y test, inflando el desempeño interno.
- **Muestra externa pequeña.** Quince imágenes de tres participantes revelan una brecha, pero no permiten estimar generalización ni equidad poblacional.
- **Privacidad.** Las fotografías propias son datos sensibles; permanecen fuera del repositorio y no deben emplearse para inferir identidad.
- **Señas dinámicas.** J y Z requieren movimiento en ASL; tratarlas como cuadros estáticos simplifica su significado y limita la validez lingüística.
- **Preprocesamiento.** 64×64 reduce detalle fino; el padding de fotos rectangulares introduce bordes ausentes del entrenamiento.
- **Alcance de producto.** No se evaluaron latencia, consumo en dispositivo, video en tiempo real, detección de mano, calibración, abstención, experiencia de usuario ni seguridad operacional.

9. Conclusiones y recomendaciones

1. **La CNN 2 base es la mejor alternativa medida.** Alcanzó 0.986973 en validación y, una vez seleccionada, 0.986590 de accuracy con pérdida 0.059055 en test.
2. **La arquitectura importa más que aumentar indiscriminadamente.** El aumento elevó CNN 1 de 0.933333 a 0.970498, pero redujo CNN 2 de 0.986973 a 0.980460. Cada transformación debe justificarse semántica y empíricamente.
3. **El test interno sobreestima la preparación para condiciones reales.** Los 2 aciertos en 15 fotografías y nueve errores de alta confianza evidencian una brecha de dominio de 0.853257.
4. **El siguiente experimento debe separar por persona o sesión.** También debe eliminar casi duplicados y reservar un conjunto externo con diversidad de piel, luz, cámara, ángulo, encuadre y tamaño de mano.
5. **La experiencia debe poder abstenerse y aprender de correcciones.** Antes de uso real se requiere calibrar confianza, definir umbrales, mostrar incertidumbre y permitir que la persona confirme o corrija sin fricción.
6. **La comunidad debe participar en el diseño.** La ampliación hacia video, J/Z dinámicas y lenguaje continuo debe realizarse con personas usuarias de ASL, protección de privacidad y evaluación por subgrupos.

Conclusión general. El laboratorio demuestra un clasificador sólido dentro de un conjunto controlado y, al mismo tiempo, muestra por qué una métrica alta no equivale a un producto accesible. La prioridad siguiente no es maximizar otro decimal del test, sino construir evidencia externa representativa y mecanismos de uso responsable.

Trazabilidad con la entrega

Evidencia solicitada	Ubicación en el informe
EDA, muestra, balance, similitud y brillo	Sección 2; figuras 1–4
Split, submuestra y preprocesamiento	Sección 3; figura 5
CNN, red densa, Random Forest y comparación	Sección 4; figuras 6–8 y tablas de resultados
Aumento y discusión de reflejos	Sección 5; figura 9
Fotografías propias y análisis de errores	Sección 6; figura 10
Accesibilidad, sesgo, limitaciones y recomendaciones	Secciones 7–9

Repositorio del proyecto: <https://github.com/Qu3zada22/Laboratorio3-ds>